GMM 潜在状態は生成を制御できるか

— Ulysses 555 スパンの状態表現による SFT 実験とその限界 —

Moka（個人研究、備忘録）

Draft · 2025

概要

前報（Ulysses GMM 転調点分析）で得た K=8 の潜在状態ラベルを、Gemma-2-2b-it の QLoRA 微調整に転用し、離散制御トークンで意識モードを切り替える生成実験を行った。結果として、同一の嗅覚的書き出しから感覚優勢と記憶優勢で異なる文体が出力された。原作に存在しないスマートフォンを題材にした場合にも、ある程度の制御性が維持された。ただし State 6（推論）の出力は訓練データの偏りにより不安定であり、評価も質的記述に留まっている。この報告はパイプラインの動作確認であり、定量的な文体評価は今後の課題として残る。

1. この実験で確かめたかったこと

前報では、Ulysses の 555 テキストスパンに対して evidence-anchored prompting（根拠引用を必須とする LLM アノテーション）を施し、mode/cause/style/place/myth の多次元特徴量を得た。これを StandardScaler で標準化したうえで GaussianMixture（K=8, random_state=42）を適用し、各スパンに潜在状態ラベルを割り当てた。事後確率エントロピーの極大点を「転調点」として抽出したところ、ジョイスの意識の流れの切れ目と概ね対応する結果を得ている。

ここで自然に浮かぶ疑問がある。その状態ラベルは、転調点分析という特定の用途に限って「たまたまうまくいった」だけではないのか。もしラベルが何か実質的な文体情報を担っているなら、それを制御信号として生成モデルに渡したとき、出力に違いが出るはずだ。出なければ、あのクラスタリングは分析上の便宜にすぎなかったことになる。

検証したい問いは三つある。

（RQ1）同じ書き出し文に対して STATE を切り替えると、生成テキストに質的な差異が現れるか。

（RQ2）原作にない主題（スマートフォン等）に対しても、状態による文体制御は機能するか。

（RQ3）複数の状態を逐次連結する「動的フロー」生成で、状態間の文体転換は読み取れるか。

以下の報告は、この三つに対する予備的な回答である。「予備的」と断るのは、評価が著者一人の質的判断に依っており、perplexity 比較も人間評価実験もまだ行っていないためだ。

2. パイプラインの構成

2.1 特徴量と GMM（前報からの引き継ぎ）

特徴量は前報と同一で、mode（知覚・内言・記憶・想像・推論・感情・対話・引用）8 次元、cause（感覚・記憶・感情駆動・言語・社会・身体・間テクスト・目標）8 次元を中心に、style/place/myth の補助次元を含む。K=8 の選択根拠は前報に譲る。本実験ではこの既存ラベルをそのまま使い、GMM のパラメータは一切再推定していない。

2.2 訓練データの組み立て

CSV（状態ラベル付き 555 行）と JSON（18 エピソードの原文テキスト）を (chapter, span_id) をキーにしてマージする。ここで一度ミスをした。初回のマージで inner join を使い、キーの型不一致（片方が文字列、片方が整数）に気づかず 555 行が 64 行まで縮退した。数日間、64 例で訓練して「なぜ生成がこんなに単調なのか」と悩んだ末、pd.merge のログを丁寧に確認して原因を突き止めた。型を揃えた後の有効行数は 555 である。

各スパンは Gemma のチャットテンプレート形式に整形した。制御トークンを以下のようにユーザターン先頭に挿入し、モデルターンに原文テキストを配置する。

<CTRL|EP={ep}|SPAN={span}|STATE={state}|ENT={ent}|>

EP はエピソード番号、SPAN はスパン番号、STATE は GMM 割当ラベル（0–7）、ENT は事後確率エントロピー（量子化して 3 段階）。このフォーマットは、先行する PocketOps プロジェクトで試した離散制御トークン方式を流用したもので、理論的根拠があるというより、手元で動いた方式をそのまま持ち込んだ。

2.3 モデルと微調整

ベースモデルは unsloth/gemma-2-2b-it-bnb-4bit。QLoRA の設定は r=16, alpha=16 で、q/k/v/o/gate/up/down_proj の全ターゲットに適用した。トークナイザには <CTRL| と |> を特殊トークンとして追加し、embedding 層をリサイズしている。

訓練は SFTTrainer（trl ライブラリ）で max_steps=100, batch_size=2, gradient_accumulation=8, lr=2e-4, optimizer=adamw_8bit。100 ステップという短さは意図的で、過学習して原文を丸暗記するリスクを避けたかった。ただし「100 で十分か」の根拠は薄い。loss カーブは下がりきる前に停止しており、200–300 ステップまで延ばす比較実験が必要だろう。

2.4 推論戦略

生成時に三つの戦略を試した。

戦略 A（Basic）：トピックをユーザターンのテキストとして渡す。最も単純だが、学習時のフォーマットとの乖離が大きく、制御トークンの効きが安定しない場面があった。

戦略 B（Pre-fill）：トピックをモデル発話の冒頭に配置する（pre-filling）。学習フォーマットに最も忠実で、制御トークンの純粋な効果を見るには向いている。ただし未知のトピックでは出力が途中で原文の断片に引きずられる傾向があった。

戦略 C（Hybrid）：LoRA 制御トークン＋自然言語による文体指定（"Focus on sensory perception" 等）＋ pre-fill の三重構成。分布外（OOD）の主題に最も安定していた。ベースモデルの instruction-following 能力を自然言語制約が活用するためと思われる。

2.5 random_state バグについて

リファクタリング中に発見した問題を一つ記録しておく。元の実装では model.generate() の引数に random_state=SEED を渡していた。これは scikit-learn の GaussianMixture 用のパラメータであり、HuggingFace の generate() では無視されるか ValueError になる。ノートブックを上から下へセルを追加しながら書いていると、名前空間が汚染され、こういうライブラリ境界をまたいだパラメータ混入が起こりやすい。torch.manual_seed() に修正した。些細なバグだが、AI 支援コーディングで「動いたからヨシ」とする習慣への警鐘として書き残す。

3. 結果

3.1 同一トピック・異なる状態（RQ1）

"The smell of frying pork kidneys" を書き出しに指定し、State 3（感覚優勢）と State 0（記憶優勢）で比較した。

State 3 の出力:

The smell of frying pork kidneys was more like it, he thought to himself. —Prawns too? What is that you call them? Keckys!

State 0 の出力:

The smell of frying pork kidneys and stewed veal kidneys came from one, boiled eggs from another: breakfast for travellers or invalids like me. —Is that you? he asked. No! was my reply by perambulatory transit.

State 3 は即時的な感覚反応（"more like it"）と対話的感嘆（"Prawns too?"）に向かう。State 0 は同じ嗅覚刺激から複合的な記憶の列挙（"stewed veal ... boiled eggs"）と過去の対話断片の回想へ展開する。差異は明瞭に見える。ただし、これが制御トークンの効果なのか、単にランダム性の揺らぎなのかは、一対の出力だけでは判別できない。同一条件で 50 回生成し語彙分布を比較する、といった統計的検証が本来は必要だ。

3.2 アナクロニズム・テスト（RQ2）

"The glowing blue light of the smartphone screen" という、ジョイスの時代にありえない書き出しを使った。狙いは、原文の暗記に頼れない状況で状態制御が効くかどうかの確認だ。

State 3（感覚・Pre-fill）は "cold glow" "long white wall" など光の物理的記述に向かい、State 0（記憶・Pre-fill）は "I wonder where they are?" "that dim bedroom" のように不在者への思慕と過去場面の回想を生成した。Hybrid 戦略では、State 3 が "fell on the newspaper that covered his breakfast tray" と簡潔な感覚描写を、State 0 が "was the only illumination in that dim bedroom. In his hand he idly caressed the smooth oval of its back" と触覚を含む記憶的描写を返した。

State 6（推論）は Hybrid でも "flashed on his eye" と短い知覚報告に終わり、推論的な展開には至らなかった。訓練データ中の State 6 該当スパン数を確認すると 555 件中 30 件程度で、偏りが出

力品質に直結している。この種の不均衡は、少数クラスのオーバーサンプリングか、あるいはK を減らして統合するか、いずれかの対処が要る。

3.3 動的フロー生成（RQ3）

状態列 [3→0→6]（感覚→記憶→推論）を指定し、各区間の末尾 6 語を次の区間の pre-fill として渡す動的フロー生成を試みた。

区間 1（State 3・感覚）：

The cold rain falling on the dark pavement hissed in a sheet underfoot the heavy shoes of an unknown pedestrian Read in the consciousness of Stephen Dedalus. The wet stone felt cool under my right foot. Then by a turn to left the road narrowed again. It was indeed but what? —Yes that! —the town park. There, facing the high gatehouse.

区間 2（State 0・記憶）：

As he passed down Frederickvale road towards the southern shore of Charleton water he thought (to answer an association in his mind): This is not my country.

区間 3（State 6・推論）：

These are false gods. This house of ill fame. If only I had no bed —he looked at it contemptuously—a poor bed, but his very own, to use as he pleased.

区間 1 では雨の触覚（"hissed", "wet stone felt cool"）が連続し、区間 2 への移行で固有地名と内的独白（"This is not my country"）が出現する。区間 3 では価値判断（"false gods"）と所有の論理（"his very own, to use as he pleased"）が前景に来る。遷移は末尾語の受け渡しで文脈的に接続されてはいるが、区間 2→3 の繋がりはやや唐突で、読み手がここに「推論への転換」を感じるかどうかは確信が持てない。

4. 何がわかり、何がわからないままか

わかったこと。GMM のラベルを制御トークンに変換して SFT に使うパイプラインは、少なくとも動く。State 3 と State 0 の対比では、同一トリガーから異なる意識展開を誘導できている。これはラベルが文体情報を多少なりとも担っていることの傍証になる。アナクロニズム・テストでも方向性としては効いており、ジョイスの意識の流れ技法における「知覚→内省」の転換構造を、計算的に——かなり粗い精度で——模倣できている可能性がある。

わからないこと。まず、K=8 が最適かどうか。前報でも書いたが、これは「正しい状態数」の主張ではない。BIC/AIC で別の K が支持される可能性は残っている。本実験は K=8 の既存ラベルをそのまま使っており、K を変えた場合の生成品質比較は未実施だ。並行して進めている銀河鉄道の夜の分析（別報）では K=2 が最適となっており、作品の複雑さとデータ次元数に応じて K が変わること自体は自然だが、Ulysses 側でも K=4 や K=6 を試すべきだったと今は思う。

次に、評価の弱さ。現状は著者一人が出力を読んで「差がある」「ない」と判断しているだけだ。perplexity の状態間比較、語彙多様性指標（TTR, MTLD 等）の統計検定、あるいは人間被験者による文体判別実験（「この文は感覚的か記憶的か」を当てさせる）が必要だろう。これらはコストがかかるが、やらなければ本報告は「面白そうに見える動作デモ」の域を出ない。

最後に、訓練データのサイズ。555 例は SFT としては非常に小さい。State 6 の不安定さは典型的なデータ不足症状だ。Ulysses 以外のモダニスト文学（Woolf, Faulkner 等）からスパンを追加する拡張も考えたが、作品間でアノテーション基準を揃えるのが難しく、手をつけていない。

5. 推論戦略の比較メモ

Basic 戦略は学習分布内の主題に対しては動くが、トピック指定の書式が訓練時と異なるため、制御トークンの効果とベースモデルの instruction-following が競合する場面があった。Pre-fill 戦略は制御トークンの効果を最も純粋に評価できるが、OOD 主題では文体が揺れる。Hybrid 戦略は三つの中で OOD に最も強かった。これは LoRA が暗黙の文体バイアスを、自然言語が明示的な制約を、pre-fill が文脈的接続をそれぞれ担い、三者の補完関係が成立しているためだと考えている。ただし、この解釈を裏付けるアブレーション実験（各要素を一つずつ外す）は行っていない。

6. 銀河鉄道の夜への接続

別報で報告した半教師あり GMM による『銀河鉄道の夜』の転調点分析では、2 次元特徴量（Morality, Isolation/Survival Urgency）上で K=2 が最適となった。Ulysses とは特徴量設計もデータ規模も異なるが、共通するのは 「事後確率エントロピーを boundaryness として使う」という枠組みだ。この共通枠組みが、言語も時代も異なる二作品で——少なくとも転調点の抽出において——意味のある結果を返すことは、手法のある種の頑健性を示唆する。

ただし、Ulysses 側（K=8, 高次元特徴量）で行った本実験の SFT 生成は、銀河鉄道側（K=2, 2 次元）にはそのまま適用できない。日本語のストリーム・オブ・コンシャスネス生成を試みるなら、ベースモデルの選択から再検討が必要になる。これは今後の展望として記録する。

7. まとめ

evidence-anchored prompting に基づく LLM アノテーションから導出した GMM 潜在状態ラベルは、転調点分析だけでなく、state-conditioned generation でもある程度機能する。少なくとも State 3（感覚）と State 0（記憶）の間には、質的に判別可能な文体差異が生じた。OOD 主題への頑健性も部分的に確認された。

しかし、この報告は定量的評価を欠いており、予備実験の域を出ない。本枠組みが文学テキストの「分析と生成の統合」として成立するかどうかは、定量評価と他作品への展開を経て初めて判断できる。パイプラインとコードは公開しており、追試可能である。

付記：再現性と公開実装

全手順は GitHub で公開している。notebooks/Ulysses_GMM_SFT.ipynb が GMM 分析・SFT 訓練・推論の統合ノートブック、data/ulysses_stream.csv が 555 スパンのアノテーション特徴量、data/Ulysses_fixed.json が 18 エピソードの原文テキスト＋メタデータ、docs/CHANGELOG.md がリファクタリング記録とバグ修正の監査ログである。

参考文献

[1] Groden, M. et al. "Networking Ulysses." Digital scholarly edition project.

[2] Gilardi, F., Alizadeh, M., & Kubli, M. (2023). ChatGPT outperforms crowd-workers for text-annotation tasks. PNAS, 120(30), e2305016120.

[3] He, X. et al. (2024). Large language models are human-level annotators for text-annotation tasks. Nature Machine Intelligence.

[4] Wei, J. et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS 2022. arXiv:2201.11903.

[5] Wang, X. et al. (2022). Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv:2203.11171.

[6] Hu, E. J. et al. (2022). LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022. arXiv:2106.09685.

[7] Dettmers, T. et al. (2023). QLoRA: Efficient Finetuning of Quantized Language Models. NeurIPS 2023. arXiv:2305.14314.

[8] Han, D. et al. (2024). Unsloth: Efficient LLM Fine-tuning. https://github.com/unslothai/unsloth.

[9] Moka (2025). 物語イベントの状態遷移解析：半教師あり GMM を用いた転調点抽出——宮沢賢治『銀河鉄道の夜』を例に. 個人研究報告.